

Tariel
Rim
GISELA

Examen Classification Automatique (DM)

Exercice 1 - k-means

1) Le regroupement $\{ (1,2), (9,12), (12,16,20) \}$ ne représente pas une segmentation possible car 12 fait partie de 2 sous-partition, la condition $\forall p \neq q, p \cap q = \emptyset$ n'est donc pas satisfaite.

2) $k=2$ avec 1 et 20 comme centre initiaux

étape 0
 $C_0 = \{ 1, 20 \}$

x	1	2	9	12	16	20
$d(x, 1)$	0	1	8	11	15	19
$d(x, 20)$	19	18	11	8	4	0

On obtient la partition suivante

$$P^0 = \{ (1, 2, 9), (12, 16, 20) \}$$

étape 1

$$C_0^1 = \frac{1+2+9}{3} = 4 \quad C_1^1 = \frac{12+16+20}{3} = 16$$

$$\Rightarrow C^1 = \{4, 16\}$$

x	1	2	9	12	16	20
$d(x, 4)$	3	2	5	8	12	16
$d(x, 16)$	15	14	7	4	0	4

$$\Rightarrow P^1 = \{ (1, 2, 9), (12, 16, 20) \}$$

On observe que $P^0 = P^1$ donc on a une stabilité des partitions

$$\Rightarrow P = \{ (1, 2, 9), (12, 16, 20) \}$$

pour $k=2$

• $k=3$ avec 1, 12 et 20 en autres initiaux

étape 0

$$C^0 = \{1, 12, 20\}$$

x	1	2	9	12	16	20
$d(x, 1)$	0	1	8	11	15	19
$d(x, 12)$	11	10	3	0	4	8
$d(x, 20)$	19	18	11	8	4	0

$$\Rightarrow P^0 = \{ (1, 2), (9, 12, 16), (20) \}$$

étape 1

$$C_0^1 = \frac{1+2}{2} = 1,5 \quad C_1^1 = \frac{9+12+16}{3} = 12,333 \quad C_2^1 = 20$$

$$\Rightarrow C^1 = \{1,5 ; 12,333 ; 20\}$$

x	1	2	9	12	16	20
$d(x, 1,5)$	0,5	0,5	7,5	10,5	14,5	18,5
$d(x, 12,333)$	11,333	10,333	3,333	0,333	3,667	7,667
$d(x, 20)$	19	18	11	8	4	0

$$\Rightarrow P^1 = \{(1,2), (9,12,16), (20)\}$$

On observe que $P^0 = P^1$ donc on a une stabilité de partition.

$$\Rightarrow P = \{(1,2), (9,12,16), (20)\}$$

3) Calcul inertie totale

On rappelle la formule de l'inertie totale d'un ensemble de points

$$I_T = \frac{1}{n} \sum_{i=1}^n d^2(w_i, g)$$

avec g le barycentre de notre ensemble de points.

Dans notre cas $n = 6$ et

$$g = \frac{1+2+9+12+16+20}{6} = 10$$

$$d^2(1, g) = 81$$

$$d^2(2, g) = 64$$

$$d^2(9, g) = 1$$

$$d^2(12, g) = 4$$

$$d^2(16, g) = 36$$

$$d^2(20, g) = 100$$

$$I_T = \frac{1}{6} (81 + 64 + 1 + 4 + 36 + 100) = 47,667$$

Calcul inertie interclasse

Rappel de la formule

$$I_{\text{inter}} = \frac{1}{n} \sum_{r=1}^h n_r d^2(g_r, g)$$

avec g_r le barycentre de la partition r

$$h = 2$$

$$g_1 = 4 \quad g_2 = 16$$

$$n_1 = 3 \quad n_2 = 3$$

$$d^2(g_1, g) = d^2(4, 10)$$

$$= 36$$

$$d^2(g_2, g) = d^2(16, 10)$$

$$= 36$$

$$I_{\text{inter}} = \frac{1}{6} (3 \times 36 + 3 \times 36)$$

$$= 36$$

$$h = 3$$

$$g_1 = 1,5 \quad g_2 = 12,333$$

$$g_3 = 20$$

$$n_1 = 2 \quad n_2 = 3 \quad n_3 = 1$$

$$d^2(g_1, g) = d^2(1,5, 10)$$

$$= 72,25$$

$$d^2(g_2, g) = d^2(12,333, 10)$$

$$= 5,443$$

$$d^2(g_3, g) = d^2(20, 10)$$

$$= 100$$

$$I_{\text{inter}} = \frac{1}{6} (2 \times 72,25 + 3 \times 5,443)$$

$$= 43,471$$

Calcul inertie intraclasse

Rappel de la formule

$$I_{\text{intra}} = \frac{1}{n} \sum_{r=1}^h n_r I(N_r)$$

avec $I(N_r)$ l'inertie totale de la partition r

$$h=2$$

$$I(N_1) = \frac{1}{3} (d^2(w, g))$$

$$d^2(1, 4) = 9$$

$$d^2(2, 4) = 4$$

$$d^2(9, 4) = 25$$

$$I(N_2) = \frac{1}{3} \sum_{i=1}^3 d^2(w_i, g)$$

$$d^2(12, 16) = 16$$

$$d^2(16, 16) = 0$$

$$d^2(20, 16) = 16$$

$$I(N_1) = 12,667$$

$$I(N_2) = 10,667$$

$$I_{intra} = 11,667$$

$$h=3$$

$$I(N_1) = \frac{1}{2} (d^2(1, 1, 5) + d^2(2, 1, 5))$$

$$d^2(1, 1, 5) = 0,25$$

$$d^2(2, 2, 5) = 0,25$$

$$I(N_2) = \frac{1}{3} (d^2(9, 12, 333) + d^2(12, 12, 333) + d^2(16, 12, 333))$$

$$d^2(9, 12, 333) = 11,109$$

$$d^2(12, 12, 333) = 0,111$$

$$d^2(16, 12, 333) = 13,447$$

$$I(N_3) = \frac{1}{1} d^2(20, 20)$$

$$d^2(20, 20) = 0$$

$$I(N_1) = 0,25$$

$$I(N_2) = 8,222$$

$$I(N_3) = 0$$

$$I_{intra} = 4,194$$

• Calcul de R^2

Rappel de la formule :

$$R^2 = \frac{I_{intra}}{I_{tot}}$$

$$h=2$$

$$R^2 = \frac{11,667}{47,667} = 0,245$$

$$h=3$$

$$R^2 = \frac{4,194}{47,667} = 0,088$$

h)		I_{intra}	I_{inter}	R^2
	$h=2$	11,667	36	0,245
	$h=3$	4,194	43,471	0,088

Le R^2 étant meilleur pour la classification avec $h=2$, ~~tout comme d'~~ , on décide donc de choisir la segmentation avec $h=2$
 → (1, 2, 9), (12, 16, 2014)

Exercice 2 - CAH

1) Quand 2 sites ont exactement la même espèce on a l'égalité suivante :

$$n_A = n_B = n_{AB}$$

$$\begin{aligned} \text{donc } d(A, B) &= \frac{n_A + n_B - 2n_{AB}}{n_A + n_B} \\ &= \frac{n_A + n_A - 2n_A}{n_A + n_A} \end{aligned}$$

$$d(A, B) = 0$$

2) Quand 2 sites n'ont aucune espèce en commun on a l'égalité suivante :

$$n_{AB} = 0$$

$$\begin{aligned} \text{donc } d(A, B) &= \frac{n_A + n_B - 2n_{AB}}{n_A + n_B} \\ &= \frac{n_A + n_B}{n_A + n_B} \end{aligned}$$

$$d(A, B) = 1$$

$$3) d(S_1, S_2) = \frac{n_{S_1} + n_{S_2} - 2n_{S_1 S_2}}{n_{S_1} + n_{S_2}}$$

$$\begin{aligned} n_{S_1} &= 10 \\ n_{S_2} &= 15 \\ n_{S_1 S_2} &= 5 \end{aligned}$$

$$\begin{aligned} d(S_1, S_2) &= \frac{10 + 15 - 2 \times 5}{10 + 15} \\ &= \frac{15}{25} = \frac{3}{5} = 0,6 \end{aligned}$$

$$d(S_1, S_3) = \frac{n_{S_1} + n_{S_3} - 2n_{S_1 S_3}}{n_{S_1} + n_{S_3}}$$

$$\begin{aligned} n_{S_1} &= 10 \\ n_{S_3} &= 11 \\ n_{S_1 S_3} &= 8 \end{aligned}$$

$$\begin{aligned} d(S_1, S_3) &= \frac{10 + 11 - 2 \times 8}{10 + 11} \\ &= \frac{21 - 16}{21} = \frac{5}{21} = 0,238 \end{aligned}$$

4) Matrice de distances

	S_1	S_2	S_3	S_4
S_1	0	0,6	0,238	0,545
S_2	0,6	0	0,692	0,185
S_3	0,238	0,692	0	0,739
S_4	0,545	0,185	0,739	0

5)

	S_1	$S_2 S_4$	S_3
S_1	0	0,545	0,238
$S_2 S_4$	0,545	0	0,692
S_3	0,238	0,692	0

2e regroupement

	$S_1 S_3$	$S_2 S_4$
$S_1 S_3$	0	0,545
$S_2 S_4$	0,545	0

3e regroupement

Dendrogramme



Le nombre de classes à retenir
est 2 : $\{S_2, S_4\}$ or $\{S_1, S_3\}$